

# Modification de hauteur, d'échelle temporelle et de timbre

Signal audiofréquence et parole  
SI 340 - Module Audio





# Partie I




## Introduction





# Introduction

## Changement de la vitesse de lecture d'un son






Origine du problème :  $y(t) = x(\alpha t) \Leftrightarrow Y(f) = \frac{1}{|\alpha|} X(\frac{f}{\alpha})$





# Introduction

**But : contrôler séparément les échelles temps et fréquence**



## Trois catégories de méthodes

- méthodes temporelles : SOLA, PSOLA
- méthodes fréquentielles : vocodeur de phase (TFCT)
- méthodes paramétriques : LPC, sinus+bruit





## Partie II

# Définitions





## Modèle de production vocale

- Modèle source / filtre linéaire variant dans le temps :

$$x(t) = \int_{-\infty}^{+\infty} g(t, \tau) e(t - \tau) d\tau$$

- Réponse en fréquence du filtre :

$$G(t, f) = \int_{-\infty}^{+\infty} g(t, \tau) e^{-j2\pi f\tau} d\tau = M(t, f) e^{j\varphi(t, f)}$$

- Source harmonique :  $e(t) = \sum_{k=1}^L e^{j\xi_k(t)}$ , où  $\frac{d\xi_k}{dt} = 2\pi f_k(t)$

- Hypothèse de quasi-stationnarité :  $\xi_k(t - \tau) \simeq \xi_k(t) - 2\pi f_k(t)\tau$

- Signal filtré :  $x(t) = \sum_{k=1}^L M(t, f_k(t)) e^{j(\xi_k(t) + \varphi(t, f_k(t)))}$





# Modèles de signaux

**Modèle de McAulay et Quatieri** (codage de la parole)

$$x(t) = \sum_{k=1}^L A_k(t) e^{j\psi_k(t)} \text{ où } \frac{d\psi_k}{dt} = 2\pi f_k(t)$$

et  $A_k(t)$  et  $f_k(t)$  sont à variation lente devant  $e^{j\psi_k(t)}$

**Modèle de Serra et Smith** (synthèse de signaux de musique)

$$x(t) = \sum_{k=1}^L A_k(t) e^{j\psi_k(t)} + b(t)$$

où  $b(t)$  est un bruit blanc filtré par un filtre variant dans le temps

## Système complet d'analyse / modification / synthèse

- estimation des composantes déterministes
- interpolation linéaire des amplitudes et cubique des phases
- soustraction de la partie déterministe pour obtenir  $b(t)$
- transformation de chacune des deux composantes
- resynthèse





# Modifications d'échelles

## Distortion temporelle

- Fonction de distortion temporelle :  $\tau = T(t)$
- Signal modifié :  $y(\tau) = \sum_{k=1}^L A_k(T^{-1}(\tau)) e^{j\phi_k(\tau)}$
- Conservation des fréquences :  $\phi_k(\tau) = 2\pi \int_0^\tau f_k(T^{-1}(u)) du$

## Modification de hauteur

- Taux de compression fréquentiel :  $\alpha(t)$
- Signal modifié :  $y(t) = \sum_{k=1}^L A_k(t) e^{j\Phi_k(t)}$
- Altération des fréquences :  $\Phi_k(t) = 2\pi \int_0^t \alpha(u) f_k(u) du$

## Réciprocité

- distortion temporelle  $T$  plus ré-échantillonnage  $T^{-1}$   
 $\Leftrightarrow$  modification de hauteur de taux  $\alpha(t) = T'(t)$








## Partie III

# Transformée de Fourier à Court Terme





## Schéma de principe





## Rappels théoriques

**Définition :**  $\tilde{X}(t_a, \nu) = \sum_{n \in \mathbb{Z}} x(n + t_a) w_a(n) e^{-j2\pi\nu n}$ , où

- la fenêtre d'analyse  $w_a(n)$  est finie, réelle et symétrique
- les instants d'analyse  $t_a$  sont indexés par un entier  $u$

**Interprétation :** convention passe-bande

- $\tilde{X}(t_a, \nu_p) = [x \star h](t_a)$  où  $h(n) = w_a(-n) e^{j2\pi\nu_p n}$
- la TF de  $h(n)$  est  $H(e^{j2\pi\nu}) = W_a(e^{j2\pi(\nu_p - \nu)})$


**Version discrète de la TFCT :** on pose  $\nu_p = \frac{p}{N}$

- $\tilde{X}(t_a, \nu_p) = \sum_{n=0}^{N-1} x(n + t_a) w_a(n) e^{-j2\pi \frac{pn}{N}}$
- la longueur des fenêtres d'analyse doit être  $\leq N$



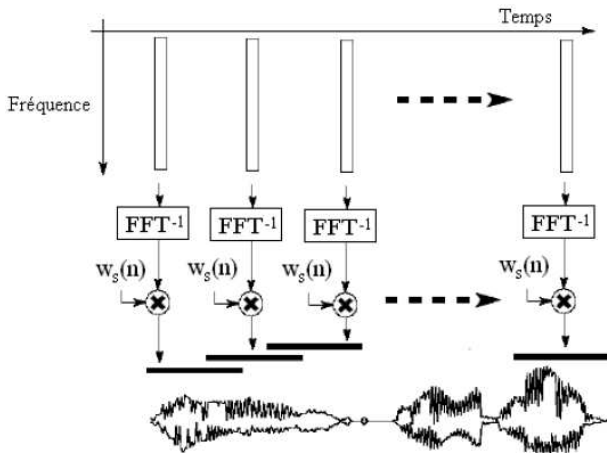


# Filtrage passe-bande équivalent





# Schéma de synthèse





# Reconstruction du signal

## Modifications et problèmes posés :

- $t_a \longrightarrow t_s, \tilde{X}(t_a(u), \nu_p) \longrightarrow Y(t_s(u), \nu_p)$
- Difficulté :  $Y$  n'est généralement pas la TFCT d'un signal

## Condition de reconstruction parfaite ( $t_s = t_a$ et $Y = \tilde{X}$ )

- synthèse par addition-recouvrement (overlapp-add ou OLA)

$$y(n) = \sum_u w_s(n - t_s(u)) y_w(n - t_s(u), t_s(u))$$

$$\text{où } \text{supp}(w_s) \subset [0, N-1] \text{ et } y_w(n, t_s(u)) = \frac{1}{N} \sum_{p=0}^{N-1} Y(t_s(u), \nu_p) e^{j2\pi\nu_p n}$$

- condition suffisante :  $\sum_u w_a(n - t_a(u)) w_s(n - t_a(u)) \equiv 1$





## Partie IV

# Vocodeur de phase





## Fréquence instantanée

- Modèle de McAulay et Quatieri :  $x(t) = \sum_{k=1}^L A_k(t) e^{j\psi_k(t)}$
- **Hypothèses de quasi-stationnarité** :  $\forall n \in \{0 \dots N-1\}$ 

$$\begin{cases} A_k(n + t_a) \simeq A_k(t_a) \\ \psi_k(n + t_a) \simeq \psi_k(t_a) + 2\pi f_k(t_a)n \end{cases}$$
- Alors  $\tilde{X}(t_a(u), \nu_p) = \sum_{k=1}^L A_k(t_a) e^{j\psi_k(t_a)} W_a(e^{j2\pi(\nu_p - f_k(t_a))})$
- Soit  $f_c$  la fréquence de coupure du filtre passe-bas  $w_a(n)$
- **Condition de bande étroite** :  $\exists ! l$  tel que  $|\nu_p - f_l(t_a)| \leq f_c$   
Interprétation (spectre harmonique) :  $N \geq \frac{4}{f_0}$
- Alors  $\tilde{X}(t_a(u), \nu_p) = A_l(t_a) e^{j\psi_l(t_a)} W_a(e^{j2\pi(\nu_p - f_l(t_a))})$   
 $\Rightarrow$  la TFCT donne accès aux phases  $\psi_l(t_a)$  modulo  $2\pi$







## Condition de recouvrement

### Levée de l'indétermination de la phase modulo $2\pi$ :

- Différence de phases entre deux instants successifs :  

$$\Delta\Phi_p = 2\pi(f_l(t_a) - \nu_p)\Delta t_a(u) + 2\pi\nu_p\Delta t_a(u) + 2n\pi$$
- Condition de recouvrement minimal :  $f_c \Delta t_a(u) < \frac{1}{2}$   
 Interprétation (fenêtre de Hanning) :  $f_c = \frac{2}{N} \Rightarrow \Delta t_a < \frac{N}{4}$
- $\exists ! n$  tel que  $|\Delta\Phi_p - 2\pi\nu_p\Delta t_a(u) - 2n\pi| < \pi$

### Estimation de la fréquence instantanée $\forall p \in \{0 \dots N-1\}$

1. calcul de la TFCT à deux instants successifs  $\rightarrow \Delta\Phi_p$
2. calcul de  $Q(n_0) = \Delta\Phi_p - 2\pi\nu_p\Delta t_a - 2n_0\pi$  tel que  $|Q(n_0)| < \pi$
3. calcul de la fréquence instantanée  $f_l(t_a) = \nu_p + \frac{Q(n_0)}{2\pi\Delta t_a}$





## Distorsion temporelle

Déroulement des phases instantanées pour une distorsion  $T(t)$

### Algorithme de modification :

1. calcul de la TFCT et de  $f_p(t_a(u))$  dans chaque canal
2. calcul du nouvel instant de synthèse  $t_s(u) = T(t_a(u))$
3. calcul de la phase instantanée de synthèse
$$\Phi_s(t_s(u+1), \nu_p) = \Phi_s(t_s(u), \nu_p) + 2\pi f_p(t_a(u)) (t_s(u+1) - t_s(u))$$
4. calcul de la TFCT de synthèse en  $u+1$ 
$$\tilde{Y}(t_s(u+1), \nu_p) = A_p(t_a(u+1)) e^{j\Phi_s(t_s(u+1), \nu_p)}$$





# Modification de hauteur

## Méthode de rééchantillonnage temporel

1. étirement temporel de distortion  $T(t) = \int_0^t \alpha(u) du$
2. ré-échantillonnage de taux  $T^{-1}(\tau)$

## Méthode de rééchantillonnage spectral

1. interpolation linéaire de la TFCT d'analyse
  - $\alpha(t_a) > 1$  : perte d'information en hautes fréquences
  - $\alpha(t_a) < 1$  : complétion du spectre en hautes fréquences
2. resynchronisation des phases en synthèse

## Problème en traitement de la parole : effet "Donald Duck"

- estimation de l'enveloppe du spectre (LPC) et "blanchiment"
- modification de hauteur, puis filtrage inverse





## Partie V

# Méthodes paramétriques





## Prédiction linéaire

**Modèle source / filtre :**  $x(t) = \int_{-\infty}^{+\infty} g(t, \tau) e(t - \tau) d\tau$

**Paramétrisation** au voisinage d'une marque d'analyse  $t_a(u)$

- $g^u$  est un filtre autorégressif (obtenu par analyse LPC)
- partie voisée :  $e^u$  est une série d'impulsions de fréquence  $f_1^u$
- partie bruitée :  $e^u$  est un bruit blanc de variance  $\sigma^{u2}$

**Synthèse sans modification :** par addition / recouvrement

**Synthèse avec modification de hauteur**

- partie voisée : on modifie la fréquence des impulsions
- partie bruitée : inchangée

**Synthèse avec modification de durée**

- les marques peuvent être dupliquées / supprimées
- les paramètres ( $g^u$ ,  $f_1^u$ ,  $\sigma^{u2}$ ) peuvent être interpolés





## Modèle Harmoniques plus Bruit (HNM)

**Modèle de Serra et Smith :** 
$$x(t) = \sum_{k=1}^L A_k(t) e^{j\psi_k(t)} + b(t)$$

**Paramétrisation du signal** autour d'une marque  $t_a(u)$  :

- partie voisée : on estime  $A_k^u$ ,  $\psi_k^u$ ,  $f_k^u$  pour chaque partiel
  - par extraction des pics de la TFCT
  - par détection de hauteur ( $f_k^u$ ) et moindres carrés ( $A_k^u$ ,  $\psi_k^u$ )
- partie bruitée : modèle auto-régressif (analyse LPC)

**Identification avec le modèle source-filtre :**

- amplitude du filtre :  $M(t_a(u), f_k^u) = A_k^u$
- phase du filtre :  $\varphi(t_a(u), f_k^u) = \psi_k^u - \xi_k(t_a(u))$

**Modification de la partie voisée :** interpolation temporelle et fréquentielle de l'amplitude et de la phase du filtre







## Estimation de la phase du filtre

**Modèle source filtre :**  $\varphi(t_a(u), f_k^u) = \Psi_k^u - \xi_k(t_a(u))$

**Déroulement de la phase modulo  $2\pi$  :**

$$\Delta\varphi_k^u = \langle \Delta\Psi_k^u - 2\pi\Delta t^u \bar{f}_k^u \rangle = (\Delta\Psi_k^u + 2\pi M_k^u) - 2\pi\Delta t^u \bar{f}_k^u$$



**Reconstruction de la phase par interpolation linéaire**





## Estimation de l'amplitude du filtre

**Modèle cepstral :**  $\log(M(t_a(u), f)) = \gamma_0 + 2 \sum_{m=1}^p \gamma_m \cos(2\pi mf)$

**Approximation directe :**  $\varepsilon = \sum_{k=1}^L (\log(A_k^u) - \log(M(t_a(u), f_k^u)))^2$

Solution :  $\gamma = (\mathbf{C}^T \mathbf{C})^{-1} \mathbf{C}^T \mathbf{a}$ , où  $\mathbf{a} = [\log(A_1^u) \dots \log(A_L^u)]^T$  et

$$\mathbf{C} = \begin{bmatrix} 1 & 2 \cos(2\pi f_1^u) & \dots & 2 \cos(2\pi p f_1^u) \\ \vdots & \vdots & \dots & \vdots \\ 1 & 2 \cos(2\pi f_L^u) & \dots & 2 \cos(2\pi p f_L^u) \end{bmatrix}$$

**Régul. :**  $\varepsilon = \sum_{k=1}^L (\log(A_k^u) - \log(M(t_a(u), f_k^u)))^2 + \lambda \mathcal{R}(M^u(f))$

où  $\mathcal{R}(M^u(f)) = \int_{-\frac{1}{2}}^{+\frac{1}{2}} \left( \frac{d}{df} \log(M(t_a(u), f)) \right)^2 df$

Solution :  $\gamma = (\mathbf{C}^T \mathbf{C} + \lambda \mathbf{R})^{-1} \mathbf{C}^T \mathbf{a}$ ,  $\mathbf{R} = 8\pi^2 \text{diag}(0, 1^2, \dots, p^2)$ .







# Synthèse du signal

## Synthèse sans modification : interpolation temporelle

- Interpolation linéaire de l'amplitude

$$A_k(t) = A_k^u \frac{t_s(u+1)-t}{t_s(u+1)-t_s(u)} + A_k^{u+1} \frac{t-t_s(u)}{t_s(u+1)-t_s(u)}$$

- Interpolation cubique de la phase  $\Psi_k(t) =$

$$\left( 2\pi f_k^u(t - t_s(u)) + \Psi_k^u \left( 1 + 2 \frac{t-t_s(u)}{t_s(u+1)-t_s(u)} \right) \right) \left( \frac{t_s(u+1)-t}{t_s(u+1)-t_s(u)} \right)^2 +$$

$$\left( 2\pi f_k^{u+1}(t - t_s(u+1)) + \Psi_k^{u+1} \left( 1 + 2 \frac{t_s(u+1)-t}{t_s(u+1)-t_s(u)} \right) \right) \left( \frac{t-t_s(u)}{t_s(u+1)-t_s(u)} \right)^2$$

où les  $\Psi_k^u$  sont les phases déroulées

## Synthèse avec modification : interpolation temporelle et fréquentielle de l'amplitude et de la phase du filtre

